

1. Introdução

A crescente prevalência de doenças crónicas associadas a hábitos alimentares inadequados, como obesidade, diabetes tipo 2 e doenças cardiovasculares, tem vindo a aumentar a importância da nutrição personalizada e do acompanhamento clínico especializado. Neste contexto, a utilização de técnicas de Ciência de Dados e Machine Learning pode contribuir para a identificação de padrões alimentares e para a previsão dos resultados obtidos pelos pacientes durante programas nutricionais.

O presente projeto tem como objetivo analisar um conjunto de dados relacionado com pacientes, planos alimentares, nutricionistas e resultados clínicos associados às dietas prescritas. Para isso, foram aplicadas diferentes técnicas de processamento e análise de dados, incluindo integração e limpeza de dados, análise exploratória, métodos de clustering e modelos de aprendizagem supervisionada.

Ao longo do projeto pretendeu-se identificar os fatores mais relevantes para o sucesso das dietas, analisar padrões comportamentais e desenvolver modelos capazes de prever a perda de peso dos pacientes com base nas suas características individuais e no acompanhamento nutricional realizado.

2. Integração de Dados

Para a realização do projeto foram utilizados quatro ficheiros CSV distintos contendo informação relativa aos pacientes, planos alimentares, nutricionistas e resultados clínicos obtidos ao longo dos programas nutricionais.

Inicialmente, os datasets foram carregados utilizando a função `read_csv()` da biblioteca `pandas`. Posteriormente, os diferentes conjuntos de dados foram integrados através da função `merge()`, utilizando como chaves principais as variáveis `patient_id`, `diet_id` e `nutritionist_id`.

O processo de integração permitiu combinar informações demográficas, clínicas, nutricionais e comportamentais num único dataset unificado, facilitando as etapas posteriores de análise e modelação preditiva.

Após a integração dos dados, o dataset final passou a conter 2523 registos e 31 características, incluindo variáveis relacionadas com:

- perfil dos pacientes;
- composição das dietas;

- experiência dos nutricionistas;
- adesão aos programas alimentares;
- e resultados clínicos associados à perda de peso.

3. Limpeza e Processamento de Dados

Após a integração dos datasets, foi realizada uma etapa de limpeza e processamento dos dados com o objetivo de melhorar a qualidade, consistência e fiabilidade da informação utilizada ao longo do projeto.

Inicialmente, foram identificadas características redundantes através da comparação entre variáveis semelhantes. Para isso, foram utilizadas operações de comparação direta entre colunas do dataset. A análise revelou que as variáveis `experience_years` e `years_experience` continham exatamente a mesma informação, enquanto a variável `bmi_redundant` apresentava inconsistências significativas relativamente à variável `baseline_bmi`, incluindo valores extremos anómalos. Assim, estas características redundantes foram removidas utilizando a função `drop()` da biblioteca `pandas`.

Posteriormente, foi realizada uma análise de valores em falta através das funções `isnull()` e `sum()`. Foram identificadas diferentes variáveis com valores nulos, destacando-se:

- `approach` (11.45%);
- `fiber_target_g` (10.07%);
- `sodium_limit_mg` (9.99%);
- `years_experience` (9.71%).

Para o tratamento dos valores em falta foram utilizadas técnicas de imputação:

- a mediana para variáveis numéricas;
- e a moda para variáveis categóricas.

Estas operações foram implementadas através da função `fillna()` da biblioteca `pandas`.

Adicionalmente, foram utilizadas as funções `drop()` para remoção de características redundantes e `StandardScaler()` da biblioteca `sklearn.preprocessing` para normalização dos dados.

Adicionalmente, foram identificados e removidos registros com valores extremos e inconsistentes, nomeadamente relacionados com altura, peso, horas de sono e alterações de peso irrealistas. Esta etapa permitiu reduzir o impacto de outliers na análise e na modelação preditiva.

Por fim, foi aplicada normalização às variáveis numéricas utilizando o método `StandardScaler` da biblioteca `sklearn.preprocessing`, permitindo uniformizar as escalas das variáveis e melhorar o desempenho dos algoritmos de Machine Learning.

Após o processo de limpeza e processamento, o dataset final passou a apresentar maior consistência e qualidade para as etapas seguintes de análise exploratória e modelação.

4. Análise Exploratória de Dados

Nesta etapa foi realizada uma análise exploratória do dataset com o objetivo de identificar relações entre as características dos pacientes, os planos alimentares, o perfil dos nutricionistas e os resultados clínicos obtidos.

Inicialmente, foram calculadas estatísticas descritivas das variáveis numéricas utilizando a função `describe()` da biblioteca `pandas`. Posteriormente, foi analisada a correlação entre as variáveis através da função `corr()` e da construção de uma matriz de correlação utilizando a biblioteca `seaborn`.

A análise da matriz de correlação revelou relações importantes entre diferentes variáveis do dataset. Destacaram-se principalmente:

- a forte correlação positiva entre `motivation_score_program` e `mean_adherence_pct` (0.86);
- a forte correlação negativa entre `mean_adherence_pct` e `weight_change_kg_6m` (-0.61);
- e a elevada correlação entre `motivation_score` e `motivation_score_program` (0.91).

Os resultados sugerem que fatores comportamentais, como motivação e adesão ao plano alimentar, apresentam maior influência na perda de peso do que variáveis demográficas isoladas.

Adicionalmente, foram analisadas relações entre variáveis categóricas e resultados clínicos através de gráficos de dispersão e boxplots. Observou-se que diferentes tipos de dieta apresentavam resultados relativamente semelhantes, enquanto a adesão ao plano alimentar demonstrou forte relação com a perda de peso obtida pelos pacientes.

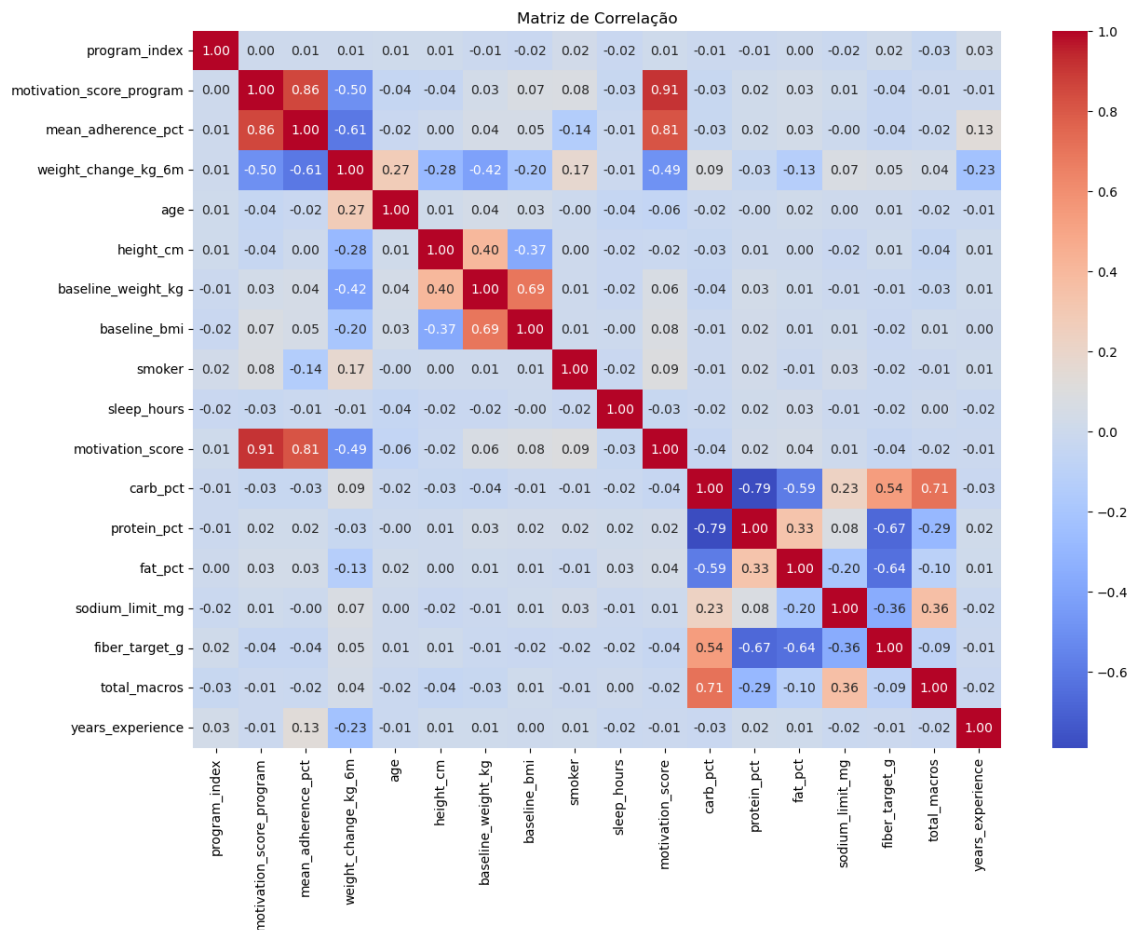


Figura 1 — Matriz de Correlação

Interpretação

A matriz de correlação permitiu identificar relações importantes entre diferentes variáveis do dataset. Observou-se uma forte correlação positiva entre a motivação do paciente e a adesão ao plano alimentar, sugerindo que pacientes mais motivados tendem a seguir melhor as dietas prescritas.

Adicionalmente, verificou-se uma forte correlação negativa entre a adesão ao plano alimentar e a variável `weight_change_kg_6m`, indicando que maiores níveis de adesão estão associados a maiores perdas de peso.

Os resultados sugerem que fatores comportamentais apresentam maior impacto no sucesso das dietas do que variáveis demográficas isoladas.




Figura 2 — Adesão à Dieta vs Perda de Peso

Interpretação

O gráfico de dispersão demonstra uma tendência negativa clara entre a adesão média ao plano alimentar e a alteração de peso dos pacientes. Observa-se que pacientes com maior adesão às dietas tendem a apresentar maiores perdas de peso ao longo do programa nutricional.

Este resultado reforça a importância da adesão ao plano alimentar como um dos fatores mais relevantes para o sucesso clínico das dietas.

Apesar da presença de alguns outliers extremos, a tendência geral observada mantém-se consistente ao longo do conjunto de dados.




Figura 3 — Perda de Peso por Tipo de Dieta

A Figura 3 apresenta a perda média de peso observada para cada tipo de dieta considerado no estudo. Verifica-se que todas as abordagens alimentares analisadas conduziram, em média, a reduções de peso, apresentando resultados relativamente próximos entre si.

Entre os diferentes tipos de dieta, a abordagem **low_carb** apresentou a maior perda média de peso, seguida pelas dietas **plant**, **high_protein** e **balanced**, que registaram valores semelhantes. Apesar desta diferença, não se observou uma superioridade suficientemente expressiva que permita concluir que um único tipo de dieta seja determinante para o sucesso dos pacientes.

Estes resultados sugerem que o desempenho dos planos alimentares poderá estar associado não apenas à composição nutricional da dieta, mas também a fatores individuais e comportamentais, como a adesão ao plano alimentar e as características do paciente, aspectos posteriormente confirmados pelas análises de clustering e pelos modelos preditivos.




Figura 4 — Perda Média de Peso por Sexo

A Figura 4 apresenta a perda média de peso por sexo. Observa-se que o grupo masculino apresentou uma perda média superior ao grupo feminino. No entanto, esta diferença não permite concluir que o sexo seja o principal fator associado ao sucesso da dieta, sendo necessário considerar também outras variáveis comportamentais e individuais.





Figura 5 -Perda Média de Peso por Experiência do Nutricionista

A Figura 5 apresenta a relação entre os anos de experiência do nutricionista e a perda média de peso dos pacientes. Observa-se uma tendência para maiores perdas de peso em programas acompanhados por nutricionistas mais experientes. No entanto, a experiência não parece explicar isoladamente os resultados obtidos, sendo também influenciada por fatores relacionados com o perfil e adesão dos pacientes.

5. Identificação de Padrões



Com o objetivo de identificar padrões mais complexos presentes nos dados, foi aplicada uma abordagem de aprendizagem não supervisionada utilizando o algoritmo K-Means, implementado através da biblioteca `sklearn.cluster`.

Inicialmente, foram selecionadas variáveis numéricas relacionadas com:

- motivação;
- adesão ao plano alimentar;
- características físicas dos pacientes;
- composição nutricional das dietas;
- e experiência dos nutricionistas.

Antes da aplicação do algoritmo, as variáveis foram normalizadas utilizando o método `StandardScaler`, garantindo que todas as características apresentassem escalas comparáveis durante o cálculo das distâncias entre observações.

Para determinar o número ideal de clusters foi utilizado o Método do Cotovelo (Elbow Method), analisando a evolução da métrica de inertia para diferentes valores de K . Observou-se uma redução significativa da inertia até aproximadamente $K=3$, sendo este o número de clusters selecionado para a análise final.

A análise dos clusters permitiu identificar diferentes perfis de pacientes e padrões alimentares:

- **Cluster 0** apresentou pacientes com elevados níveis de motivação e adesão às dietas, associados às maiores perdas de peso médias. Este grupo apresentou também maior percentagem de proteína nas dietas prescritas.
- **Cluster 1** apresentou os menores níveis de motivação e adesão ao plano alimentar, registando também as menores perdas de peso médias. Este grupo representa pacientes menos comprometidos com os programas nutricionais.
- **Cluster 2** apresentou elevados níveis de adesão e motivação, associados a dietas com maior percentagem de carboidratos e fibra, mantendo resultados clínicos positivos em termos de perda de peso.

Os resultados obtidos demonstram que fatores comportamentais, como motivação e adesão ao plano alimentar, apresentam forte influência no sucesso das dietas, independentemente do tipo específico de alimentação prescrita.

6. Aplicação de Modelos de Previsão

Para a previsão da variável `weight_change_kg_6m` foram aplicados diferentes modelos de aprendizagem supervisionada utilizando a biblioteca `sklearn`. O objetivo principal consistiu em prever a perda de peso dos pacientes com base nas suas características clínicas, comportamentais, nutricionais e no perfil dos nutricionistas responsáveis pelo acompanhamento.

Inicialmente, o conjunto de dados foi dividido em três subconjuntos:

- treino (1662 registos);
- validação (356 registos);
- teste (357 registos).

Antes da modelação, foram aplicadas técnicas de codificação de variáveis categóricas utilizando `get_dummies()` da biblioteca `pandas`, permitindo transformar variáveis textuais em representações numéricas adequadas aos algoritmos de Machine Learning.

Foram avaliados três modelos distintos:

- Linear Regression;
- Decision Tree Regressor;
- Random Forest Regressor.

A avaliação dos modelos foi realizada através das métricas:

- MAE (Mean Absolute Error);
- RMSE (Root Mean Squared Error);
- R^2 (Coeficiente de Determinação).

Os resultados obtidos foram os seguintes:

Modelo	MAE	RMSE	R^2
Linear Regression	2.06	2.80	0.851
Decision Tree Regressor	3.04	3.88	0.715
Random Forest Regressor	2.08	2.75	0.856

Os resultados demonstram que o modelo Random Forest Regressor apresentou o melhor desempenho global, obtendo o maior valor de R^2 e o menor erro quadrático médio. No entanto, a diferença relativamente à Regressão Linear foi reduzida, sugerindo que grande parte das relações presentes nos dados apresenta um comportamento relativamente linear.

Adicionalmente, foi realizada uma análise de importância das características utilizando o atributo `feature_importances_` do modelo Random Forest. Os resultados mostraram que as variáveis mais relevantes para prever a perda de peso foram:

- cluster do paciente;
- adesão ao plano alimentar;
- peso inicial;
- idade;
- e motivação do paciente.

Os resultados reforçam a importância dos fatores comportamentais no sucesso dos programas alimentares, destacando particularmente a adesão às dietas como um dos principais fatores associados à perda de peso.




Figura — Importância das Características no Modelo Random Forest

Interpretação

A análise de importância das características revelou que as variáveis mais relevantes para a previsão da perda de peso foram o cluster do paciente, a adesão média ao plano alimentar (mean_adherence_pct) e o peso inicial (baseline_weight_kg).

Os resultados demonstram que fatores comportamentais e o perfil geral dos pacientes apresentam maior influência no sucesso das dietas do que características isoladas relacionadas apenas com o tipo de alimentação.

Além disso, variáveis como idade, experiência do nutricionista e motivação também apresentaram relevância moderada no desempenho do modelo preditivo.

7. Discussão Crítica dos Resultados

A comparação entre os diferentes modelos de previsão permitiu identificar diferenças significativas no desempenho das abordagens utilizadas. Entre os modelos avaliados, o Random Forest Regressor apresentou o melhor desempenho global, obtendo o maior valor de R^2 (0.856) e os menores erros de previsão.

O bom desempenho deste modelo pode ser explicado pela sua capacidade de capturar relações não lineares entre as variáveis, reduzindo simultaneamente problemas de overfitting através da combinação de múltiplas árvores de decisão.

Apesar disso, a Linear Regression apresentou resultados bastante próximos, alcançando um valor de R^2 de 0.851. Este resultado sugere que muitas das relações presentes no dataset apresentam um comportamento relativamente linear,

especialmente no caso das variáveis relacionadas com motivação, adesão ao plano alimentar e perda de peso.

Do ponto de vista prático, a Regressão Linear apresenta vantagens importantes relativamente à interpretabilidade e simplicidade do modelo, tornando-se potencialmente mais adequada para utilização em contexto clínico real, onde a facilidade de explicação dos resultados é um fator relevante.

Por outro lado, o modelo Decision Tree Regressor apresentou o pior desempenho entre os modelos avaliados. Este comportamento pode estar associado à elevada sensibilidade das árvores de decisão a ruído, outliers e pequenas variações nos dados, dificultando a capacidade de generalização do modelo.

A análise de importância das características revelou ainda que fatores comportamentais, como adesão à dieta e motivação dos pacientes, apresentam maior impacto no sucesso dos programas alimentares do que variáveis demográficas isoladas ou características específicas das dietas prescritas.

Durante o desenvolvimento do projeto foram também identificadas algumas limitações no conjunto de dados, nomeadamente:

- presença de valores extremos;
- inconsistências em variáveis categóricas;
- existência de valores em falta;
- e ausência de fatores externos potencialmente relevantes, como contexto psicológico ou socioeconómico dos pacientes.

De forma geral, os resultados obtidos demonstram que técnicas de Ciência de Dados e Machine Learning podem ser utilizadas com sucesso na análise de padrões nutricionais e na previsão da perda de peso em programas alimentares personalizados.

8. Conclusão

Os resultados obtidos demonstraram que fatores comportamentais, especialmente a adesão ao plano alimentar e a motivação dos pacientes, apresentaram maior influência no sucesso das dietas do que o tipo específico de alimentação.

A aplicação de técnicas de clustering permitiu identificar diferentes perfis de pacientes, enquanto os modelos preditivos demonstraram elevada capacidade de previsão, com destaque para o Random Forest.

Conclui-se que técnicas de Ciência de Dados podem contribuir para decisões nutricionais mais eficazes e personalizadas.